



Datos en el Aire: Análisis Multivariado de la Calidad del Aire en la Zona Metropolitana de Monterrey

Entregable 2, Etapa 2: Ruta de análisis y exploración descriptiva orientada al objetivo

Miembros
Equipo 3

Ricardo Ballesteros Amavizca
Landon Mauricio Treviño Ortiz
Josué Olvera Zozaya

A01255358
A01199312
A00842044

Repositorio: <https://github.com/Ricardo-B04/sima-monitoreo-ambiental>

Profesores: Blanca Rosa Ruiz Hernández y Jesús Armenta Segura
Tecnológico de Monterrey – Campus Monterrey
7 de octubre de 2026

1. Objetivo de indagación

El objetivo es el mismo que en la Etapa 1; no se modificó. **Pregunta:** ¿cómo se relacionan las concentraciones de ozono con sus precursores (NO , NO_2 , NO_x) y con las variables meteorológicas (temperatura, radiación solar, viento, humedad y presión) en las estaciones de SIMA entre 2020 y 2025, y qué combinación de estas variables permite explicar y clasificar los episodios de excedencia de ozono? **Objetivo general:** identificar y cuantificar, mediante técnicas de análisis multivariado, la relación entre el ozono, sus precursores y la meteorología en la ZMM para explicar y clasificar los episodios de excedencia. Se mantienen las decisiones de preparación de la Etapa 1: unidad de análisis estación–día, periodo de modelado 2021–2025 (2020 sólo se describe por su baja cobertura) y excedencia definida como máximo diario de la media móvil de 8 h por encima de 60 ppb (criterio principal) o 51 ppb (criterio 2026), constantes en todo el periodo [4].

2. Ruta de análisis propuesta

La Tabla 1 resume las técnicas previstas [1]. El orden va de lo descriptivo a lo predictivo: primero se reduce y agrupa la información sin usar la excedencia (PCA y conglomerados), luego se prueba si los grupos difieren y, al final, se modela y clasifica. Los modelos supervisados se validarán por bloques temporales (entrenar con 2021–2024 y evaluar en 2025) y dejando una estación fuera, porque los días consecutivos de una misma estación no son independientes.

Técnica	Qué permitirá estudiar	Variables y función	Por qué es adecuada
Componentes principales (PCA)	Ejes que resumen la variación conjunta de precursores y meteorología.	Interdependencia (sin variable respuesta): $\log \text{NO}$, $\log \text{NO}_2$, $\log \text{NO}_x$ 06–09 h, temperatura máxima, radiación, humedad, viento (u , v , velocidad) y presión, estandarizadas; O_3 y estación sólo para interpretar.	Las variables están correlacionadas (Fig. 3b); el PCA elimina la redundancia y da componentes ortogonales para modelos posteriores.
Conglomerados (Ward y k -medias)	(a) Grupos de estaciones con perfil similar; (b) tipologías de días.	(a) Objeto: estación; atributos: perfil medio estandarizado. (b) Objeto: estación–día; atributos: componentes del PCA.	Formaliza el gradiente entre estaciones (Fig. 1) y permite ver si ciertos tipos de día concentran excedencias.
T^2 de Hotelling / MANOVA	Si el vector de medias difiere entre días con y sin excedencia y entre sectores.	Respuesta: vector de predictores; factores: excedencia, sector.	Prueba multivariada que precede al discriminante; controla el error tipo I frente a muchas pruebas t .
Regresión lineal múltiple	Cuánto cambia el O_3 con cada variable, manteniendo las demás constantes.	Dependiente: O_3 máximo de 8 h (ppb). Independientes: precursores (NO_x o NO y NO_2), meteorología, ciclo anual; estación como <i>dummies</i> (control).	Respuesta continua y aproximadamente simétrica (asimetría 0.6); cuantifica efectos y permite separar meteorología de tendencia entre años.
Análisis discriminante (lineal y cuadrático)	Qué combinación de variables separa los días con y sin excedencia.	Agrupación: excedencia (60 y 51 ppb). Discriminantes: predictores continuos o componentes del PCA.	Es la técnica del objetivo 5; el cuadrático se justifica si las covarianzas difieren entre grupos (Secc. 4.3).
Regresión logística	Probabilidad de excedencia (comparación con el discriminante).	Dependiente: excedencia; independientes: los del discriminante más estación.	No exige normalidad multivariada ni covarianzas iguales; admite la estación como factor.

Tabla 1: Ruta de análisis: técnicas, variables y función de cada una.

3. Datos y variables relevantes

Se usa la base diaria limpia de la Etapa 1 (`sima_diaria_estacion.csv`): 15 estaciones $\times$ 1,826 días de 2021–2025 = 27,390 estación–días, de los cuales 24,931 (91.0 %) tienen ozono válido y 19,585 (71.5 %)

tienen ozono y todas las variables del modelo. Un valor diario requiere al menos 18 horas válidas. La Tabla 2 describe las variables.

Variable	Significado	Tipo, unidad	Mín-máx [mediana; RIC]	Falt. %	Valores inusuales / notas
Estación	Sitio de monitoreo; se agrupa en sector (poniente, centro, oriente)	Nominal, 15 niveles	–	0	NO3 con 51.6 % de días válidos de O ₃
Fecha (calendario)	Mes, temporada, fin de semana, ciclo anual	Temporal	2021-01-01 a 2025-12-31	0	–
O ₃ máx. 8 h	Máximo diario de la media móvil de 8 h	Continua, ppb	2.5–123.9 [43.6; 33.8–54.6]	9.0	Asimetría 0.6; extremos plausibles conservados
Excedencia	O ₃ máx. 8 h > 60 (o 51) ppb	Binaria	16.9 % (32.0 %) de días “sí”	9.0	Clases desbalanceadas
NO, NO ₂	Medias diarias de los precursores	Continua, ppb	0.5–298 [7.2; 4.5–13.5]; 0.1–84 [12.9; 8.6–19.0]	11.1; 10.9	Asimetría 4.1 y 1.4: se usa log(1 + x)
NO _x 06–09 h	Media de NO _x de 06 a 09 h (tráfico matutino)	Continua, ppb	0.7–394 [26.7; 16.7–46.1]	9.9	Asimetría 2.5; NO _x ≠ NO + NO ₂ en 1 % de horas
Temp. máxima	Máximo diario de TOUT	Continua, °C	–0.6–45.1 [30.3; 25.1–33.9]	8.9	Mínimo real: helada de feb. 2021
Radiación	Media diaria de SR	Continua, kW/m ²	0–0.79 [0.15; 0.09–0.20]	7.4	146 días >0.4 (90 en NE2–2021, 51 en NO2): posible falla de escala
Humedad	Media diaria de RH	Continua, %	1.5–96.1 [57.8; 47.5–67.3]	13.0	71 días <10 %, poco plausibles
Viento: vel., <i>u</i> , <i>v</i>	Velocidad media y componentes este-oeste (<i>u</i>) y norte-sur (<i>v</i>), derivadas de WSR y WDR	Continua, km/h	vel. 0.7–26.1 [8.1]; <i>u</i> –22–19 [–4.1]	7.6; 9.4	<i>u</i> < 0 en 85.5 % de los días: viento predominante del este
Presión	Media diaria de PRS	Continua, mmHg	682–748 [714.5; 710–722]	6.5	Depende de la altitud: se usa como anomalía por estación

Tabla 2: Variables del análisis (estación–días de 2021–2025). Falt.: porcentaje de los 27,390 estación–días sin valor diario válido. RIC: rango intercuartílico.

La estación de monitoreo. Las 15 estaciones difieren en altitud (334 a 702 msnm), en exposición a emisiones y en su posición respecto del viento dominante, por lo que una misma combinación de precursores y meteorología no tiene por qué producir el mismo ozono en todas. Se incorpora de cuatro formas: (1) como factor de comparación, individualmente y agrupada en tres sectores según la zona de SIMA (poniente: NO, NO₂, NO₃, SO, SO₂; centro: CE, NTE, NTE2, SUR; oriente: NE, NE2, NE3, SE, SE2, SE3); (2) centrando las variables por estación (anomalías), para separar la variación día a día de las diferencias fijas de ubicación, lo cual es indispensable para la presión; (3) como variable *dummy* de control en las regresiones; y (4) como objeto de los conglomerados y como bloque de validación.

4. Exploración descriptiva orientada al objetivo

4.1 ¿Difiere el ozono entre estaciones?

Sí, y de forma ordenada en el espacio (Fig. 1; detalle en Anexo A1). La mediana del sector poniente es 47.8 ppb con 24.6 % de días sobre 60 ppb, frente a 44.4 ppb y 18.1 % en el centro y 40.6 ppb y 10.1 % en el oriente. La mediana de cada estación se asocia con su altitud (ρ de Spearman = 0.87, $n = 15$), pero la altitud y la longitud están casi confundidas ($\rho = -0.97$): las estaciones altas son las del poniente, que




Figura 1: O₃ máximo de 8 h por estación (2021–2025), ordenadas por mediana; bajo cada estación, su altitud. Arriba, porcentaje de días >60 ppb. Líneas: 60 ppb (discontinua) y 51 ppb (punteada).

quedan viento abajo del flujo predominante del este. Con estos datos no se puede separar el efecto de la altura del transporte. NE2 (Apodaca) y NTE2 (Universidad) tienen el ozono más bajo de su sector y la NO_x mediana más alta de la red (30.9 y 36.3 ppb), compatible con consumo local de ozono por NO [3]. Para el objetivo, la estación debe controlarse antes de atribuir efectos a la meteorología.

4.2 ¿Cómo cambia en el año, entre años y por tipo de día?




Figura 2: (a) Mediana mensual del O₃ máximo de 8 h por año (línea punteada: 51 ppb). (b) Porcentaje de días con excedencia (>60 ppb) por año y sector.

El ciclo anual es bimodal (Fig. 2a; Anexo A2): el porcentaje de excedencias sube en marzo–mayo (máximo en mayo, 31.5 %), baja en julio (12.0 %) y repunta en septiembre–octubre (alrededor de 21 %); diciembre y enero tienen menos de 5 %. El descenso de verano ocurre con las temperaturas máximas más altas del año (34–35 °C), pero también con la mayor velocidad de viento y la menor NO_x, de modo que la temperatura por sí sola no explica la estacionalidad. Esto coincide con lo reportado en la ZMM, donde la meteorología gobierna el ciclo estacional del ozono [2].

Entre años, con el umbral fijo de 60 ppb, el porcentaje de excedencias fue 13.6, 13.2 y 12.6 % en 2021–2023 y subió a 19.9 % en 2024 y 24.7 % en 2025 (Fig. 2b). El aumento aparece en los tres sectores y en 13 de 15 estaciones (mediana de +6.4 puntos porcentuales), por lo que no se debe sólo al cambio de norma ni a qué estaciones reportaron. Sin embargo, 2025 también fue el año más cálido (mediana de temperatura máxima 31.0 frente a 29.9–30.3 °C), así que falta controlar la meteorología para saber si hay un deterioro real. Por tipo de día, en fin de semana la NO_x matutina baja 26 % (mediana de

21.6 frente a 29.2 ppb) y el ozono no baja (44.2 frente a 43.2 ppb), comportamiento compatible con un régimen en el que reducir NO no reduce el ozono [3].

4.3 ¿Qué variables se asocian con el ozono y con la excedencia?




Figura 3: Variables centradas por estación (2021–2025). (a) Diferencia estandarizada de medias entre días con y sin excedencia de 60 ppb (líneas punteadas: ± 0.5). (b) Correlación de Spearman entre O₃ y los predictores.

Dentro de cada estación, los días con excedencia son sobre todo más calurosos ($d = 0,90$), más secos ($d = -0,66$), de presión relativamente baja ($d = -0,58$) y más soleados ($d = 0,53$) (Fig. 3a). Los precursores separan menos: NO₂ y NO_x matutina son algo mayores en los días con excedencia ($d \approx 0,3$) y el NO casi no difiere. Las correlaciones con el ozono son moderadas (Fig. 3b): 0.44 con la temperatura, 0.41 con la radiación, $-0,45$ con la humedad, $-0,30$ con la presión y $|\rho| < 0,16$ con los precursores y el viento. La relación con la temperatura se mantiene en las cuatro temporadas (ρ de 0.38 a 0.52). El ozono del día anterior tiene la correlación más alta ($\rho = 0,70$), lo que indica persistencia de los episodios. Entre predictores hay redundancia: NO, NO₂ y NO_x se correlacionan alrededor de 0.8, y la temperatura con la radiación (0.6) y con la presión ($-0,6$). Además, la temperatura máxima varía menos en los días con excedencia (razón de desviaciones 0.59), señal de covarianzas distintas entre grupos. Para el objetivo, esto sugiere que la meteorología aportará la mayor parte de la separación, que conviene usar componentes o una sola medida de NO_x, y que el discriminante cuadrático o la logística pueden ajustarse mejor que el lineal.

4.4 ¿Qué problemas de datos pueden influir?

La cobertura no es homogénea (Anexo A1). NO₃ sólo tiene 468 días completos y NTE 707 (ninguno en 2025); NE tiene 6 % de días completos en 2025. La humedad es la variable que más limita los casos completos (8.0 % faltante en días con ozono válido). Los días excluidos por incompletos tienen algo más de excedencias que los completos (18.3 frente a 16.5 %), un sesgo pequeño pero en la dirección de subestimar los episodios. Con la distancia de Mahalanobis, 580 casos completos (3.0 %) superan el percentil 99.9 de χ^2_{11} ; se concentran en NO₂ (136) y NE₂ (74), las mismas estaciones con radiación media diaria inusualmente alta, lo que apunta a un problema de sensor más que a episodios reales.

5. Síntesis

Lo descubierto. El ozono varía de forma sistemática en el espacio (más alto en el poniente), en el año (dos máximos, primavera y otoño) y entre años (más excedencias en 2024–2025 con umbral fijo). Dentro de cada estación, la excedencia se asocia sobre todo con calor, sequedad, presión baja y radiación; los precursores tienen una relación débil y no lineal con el ozono diario.

Resultados ligados al objetivo. El tamaño de las diferencias entre días con y sin excedencia (Fig. 3a) anticipa qué variables pesarán en el discriminante; la correlación entre predictores justifica el PCA; el gradiente entre estaciones justifica los conglomerados y el control por estación; y el aumento de 2024–2025 es la pregunta que la regresión con control meteorológico debe responder.

Limitaciones. Cobertura desigual entre estaciones y años (NO₃, NTE, NE en 2025, todo 2020); posibles fallas de sensor no detectadas por los rangos (radiación en NE2 y NO₂, humedad <10 %); presión dominada por la altitud; altitud y longitud confundidas; clases desbalanceadas; dependencia temporal entre días; umbrales de la NOM-020-SSA1-2021 aún por verificar en el Diario Oficial; y falta de compuestos orgánicos volátiles, el otro precursor del ozono.

Lo que falta y el camino a seguir. (1) Revisar con SIMA los valores inusuales de radiación y humedad y decidir si se invalidan; (2) PCA sobre anomalías por estación; (3) conglomerados de estaciones y de días; (4) T^2 de Hotelling por excedencia y sector; (5) regresión lineal con estación, ciclo anual y año, revisando VIF y autocorrelación; (6) discriminante lineal y cuadrático frente a logística, con validación temporal y por estación, reportando sensibilidad y especificidad con 60 y 51 ppb.

Nuevas preguntas. ¿El ozono alto del poniente se debe a la altitud o al transporte desde el oriente? ¿Por qué baja en julio y agosto si son los meses más calurosos? ¿El aumento de 2024–2025 persiste al controlar la meteorología? ¿El efecto de fin de semana se repite en todas las estaciones? ¿Conviene usar el ozono del día anterior como predictor, dado que aporta mucho pero introduce dependencia temporal?

6. Reproducibilidad del análisis

Repositorio: <https://github.com/Ricardo-B04/sima-monitoreo-ambiental>. El archivo README.md indica el orden de ejecución: `analisis/01_comprension_datos.Rmd` y `analisis/02_preparacion_datos.Rmd` (diagnóstico y limpieza; requieren los libros originales de SIMA, que no se publican) generan la base limpia `datos/procesados/sima_diaria_estacion.csv`; `analisis/03_exploracion_descriptiva.Rmd` parte de ese .csv y produce todas las cifras, tablas y figuras de este informe, y `entregables/entregable2/main.tex` compila el documento.

7. Declaratoria de uso de inteligencia artificial

Opción B. Se utilizó IA de la siguiente forma. Herramienta: Posit Assistant, asistente de IA generativa integrado en RStudio. **Uso realizado:** apoyo en el código en R de la exploración descriptiva, el cálculo de cifras, las figuras y tablas y la redacción de borradores. **Secciones donde se utilizó:** 2 a 6 y anexos. **Validación realizada por los estudiantes:** el equipo ejecutó de manera independiente `analisis/03_exploracion_descriptiva.Rmd` a partir de la base limpia y contrastó cada cifra, tabla y figura citada en el texto con la salida reproducida; además revisamos el código generado, verificamos los supuestos estadísticos de cada análisis y reescribimos las interpretaciones y conclusiones con criterio propio. Confirmamos que revisamos y verificamos el contenido y asumimos la responsabilidad del contenido final entregado.

Referencias

- [1] Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6.^a ed.). Pearson Prentice Hall.
- [2] Hernández-Romero, K., et al. (2026). Persistent air pollution regimes and regulatory exceedances of PM₁₀, PM_{2.5}, and O₃ in the Monterrey Metropolitan Area, Mexico. *City and Environment Interactions*, 31, 100410. doi:10.1016/j.cacint.2026.100410
- [3] Seinfeld, J. H., & Pandis, S. N. (2016). *Atmospheric Chemistry and Physics: From Air Pollution to Climate Change* (3.^a ed.). Wiley.
- [4] SINAICA, INECC. Normas Oficiales Mexicanas de salud ambiental (NOM-020-SSA1-2021). <https://sinaica.inecc.gob.mx/pags/noms.php>

Anexos

Estación	Zona	Sector	msnm	Días O ₃	% válidos	Completos	Mediana O ₃	P90 O ₃	% >60	% >51	Mediana NO _x
NO	Noroeste	Poniente	568	1619	88.7	1189	49.4	71.7	26.1	46.3	18.6
SO	Suroeste	Poniente	674	1733	94.9	1320	47.8	73.7	25.9	43.2	23.8
NO2	Noroeste 2	Poniente	702	1765	96.7	1030	47.5	72.9	25.0	42.9	17.3
SO2	Suroeste 2	Poniente	636	1798	98.5	1592	47.3	72.5	24.1	41.3	21.0
CE	Centro	Centro	562	1712	93.8	1594	47.1	71.2	23.0	39.8	20.2
NO3	Noroeste 3	Poniente	607	942	51.6	468	45.8	68.1	20.0	39.3	20.3
SUR	Sur	Centro	555	1743	95.5	1573	45.2	70.2	21.6	37.9	17.3
NTE	Norte	Centro	503	1694	92.8	707	44.9	65.0	15.9	32.9	17.8
SE	Sureste	Oriente	500	1767	96.8	1556	43.8	65.8	16.0	31.4	17.5
NE	Noreste	Oriente	474	1676	91.8	1162	43.4	61.4	11.8	27.8	19.5
SE2	Sureste 2	Oriente	387	1575	86.3	1397	43.2	62.6	13.2	27.8	15.6
NE3	Noreste 3	Oriente	346	1734	95.0	1321	41.0	58.0	8.0	20.1	18.9
NTE2	Norte 2	Centro	520	1737	95.1	1671	40.6	61.8	11.7	23.1	36.3
SE3	Sureste 3	Oriente	334	1769	96.9	1692	38.8	57.9	8.2	18.8	13.5
NE2	Noreste 2	Oriente	432	1667	91.3	1313	33.0	51.1	3.5	10.1	30.9

Tabla A1: Resumen por estación, 2021–2025 (referido en la Secc. 4.1). Completos: días con ozono y todas las variables del modelo. O₃: máximo de 8 h (ppb). NO_x: media diaria (ppb).

Mes	Mediana O ₃	% >60	Temp. máx.	Radiación	Humedad	NO _x	Viento
Ene	36.6	2.6	21.6	0.102	54	34.7	6.6
Feb	44.1	13.6	24.5	0.136	52	31.9	7.3
Mar	50.0	23.6	28.8	0.167	50	22.2	8.3
Abr	47.0	22.9	30.6	0.169	58	17.4	9.3
May	50.4	31.5	33.0	0.177	60	16.0	9.6
Jun	43.8	20.4	34.5	0.205	56	13.9	10.3
Jul	43.0	12.0	34.2	0.192	58	13.9	9.7
Ago	45.2	14.4	35.1	0.192	54	14.5	9.4
Sep	47.1	21.7	32.4	0.166	59	17.1	8.0
Oct	44.2	21.4	29.0	0.137	64	23.8	7.0
Nov	37.1	11.5	25.1	0.102	66	29.9	6.3
Dic	34.6	4.8	23.4	0.091	63	41.5	5.7

Tabla A2: Medianas mensuales, 2021–2025 (referido en la Secc. 4.2). O₃: máximo de 8 h (ppb); % > 60: días con excedencia; temperatura máxima (°C); radiación (kW/m²); humedad (%); NO_x (ppb); velocidad del viento (km/h). Muestra que el descenso de julio coincide con más viento y menos NO_x.




Figura A1: Porcentaje de estación-días con ozono y todas las variables del modelo válidas, por estación y año (referido en la Secc. 4.4). Justifica excluir 2020 de los modelos y vigilar NO3, NTE y NE en 2024–2025.