



Datos en el Aire: Análisis Multivariado de la Calidad del Aire en la Zona Metropolitana de Monterrey

Entregable 1, Etapa 1: Conociendo el negocio y comprensión y preparación de los datos

Miembros
Equipo 3

Ricardo Ballesteros Amavizca
Landon Mauricio Treviño Ortiz
Josué Olvera Zozaya

A01255358
A01199312
A00842044

Repositorio: <https://github.com/Ricardo-B04/sima-monitoreo-ambiental>

Profesores: Blanca Rosa Ruiz Hernández y Jesús Armenta Segura
Tecnológico de Monterrey – Campus Monterrey
1 de octubre de 2026

1. Introducción

1.1 Por qué importa la calidad del aire

La contaminación atmosférica es un problema de salud pública y no solo ambiental. La Organización Mundial de la Salud (OMS) actualizó en 2021 sus guías globales tras una revisión sistemática de la evidencia y estimó que cerca de 80 % de las muertes prematuras atribuidas a las $PM_{2,5}$ podrían evitarse si los países alcanzaran los niveles anuales recomendados [1, 3]. Aun así, solo 10 % de los asentamientos evaluados por la OMS tenía niveles anuales de $PM_{2,5}$ o PM_{10} alineados con esas guías [2]. En México, la evaluación oficial reconoció que, de las 140 estaciones que medían PM_{10} , solo 87 generaron información suficiente para evaluar la norma y de ellas únicamente 8 cumplieron los valores límite [5].

La dimensión social es igual de relevante. Un ensayo reciente sobre salud pública ambiental sostiene que los riesgos ambientales, entre ellos la contaminación del aire, deben evaluarse combinando métodos cuantitativos y cualitativos, porque factores socioculturales como la educación, la experiencia previa y la confianza en las instituciones condicionan cómo la población percibe el riesgo y si adopta conductas preventivas [8]. Medir bien es, por tanto, una condición para que la ciudadanía confíe en la información y participe en las decisiones.

1.2 Contaminantes, variables y su medición

Las guías de la OMS cubren seis contaminantes: $PM_{2,5}$, PM_{10} , ozono (O_3), dióxido de nitrógeno (NO_2), dióxido de azufre (SO_2) y monóxido de carbono (CO) [1]. En el caso de Monterrey, los estudios locales coinciden en que los problemas principales son PM_{10} , O_3 y $PM_{2,5}$, que son los que acumulan más días fuera de norma y una tendencia creciente en las últimas dos décadas, mientras que CO, NO_2 y SO_2 se mantienen dentro de norma [12]. Esta red mide además variables meteorológicas (temperatura, humedad relativa, radiación solar, presión barométrica, velocidad y dirección del viento y lluvia) [16], que son indispensables porque la formación y dispersión de los contaminantes depende de ellas.

1.3 Normas y su problemática

México regula las partículas con la NOM-025-SSA1-2021 y el ozono con la NOM-020-SSA1-2021, ambas publicadas en 2021 con cumplimiento gradual [5, 6]. La Tabla 1 compara los valores vigentes en 2026 con las guías de la OMS.

Contaminante	Indicador	Norma mexicana (desde 2026)	Guía OMS 2021
PM_{10}	Promedio 24 h	$50 \mu g/m^3$	$45 \mu g/m^3$
$PM_{2,5}$	Promedio 24 h	$25 \mu g/m^3$	$15 \mu g/m^3$
$PM_{2,5}$	Promedio anual	$10 \mu g/m^3$	$5 \mu g/m^3$
O_3	Máximo diario, media móvil 8 h	0.051 ppm	$100 \mu g/m^3$ (aprox. 51 ppb)

Tabla 1: Valores límite mexicanos para 2026 [6, 7] y guías de la OMS [1, 4].

La problemática tiene tres aristas. Primero, el endurecimiento es escalonado: para PM_{10} el límite de 24 h pasa de $70 \mu g/m^3$ en 2022–2023 a 60 en 2024–2025 y a 50 desde 2026, y para el ozono de 0.065 a 0.060 y a 0.051 ppm [6]. Segundo, la autoridad federal advirtió que, al ser más protectoras, las nuevas cifras harán que en algunas ciudades parezca que la contaminación aumenta porque habrá más días en incumplimiento, sin que eso implique necesariamente un deterioro real [7]. Para un análisis de 2020 a 2025 esto significa que el umbral cambia dentro del periodo y que las excedencias no son comparables año con año si no se fija un criterio. Tercero, no existe una norma oficial mexicana ni una guía mundial que homogenice los planes de contingencia, por lo que cada entidad federativa tiene los suyos [7].

1.4 Dificultades de la medición

Medir la calidad del aire no es solo instalar sensores. Los equipos tienen un rango del fabricante y un rango de operación válido que cambia por año, y las lecturas fuera de esos rangos deben descartarse; los documentos de SIMA incluyen notas específicas por año y parámetro (por ejemplo, en 2020 no se consideran velocidades de viento superiores a 75 km/h ni lecturas de radiación solar por encima del rango) [16]. A ello se suman los huecos por fallas o mantenimiento, la cobertura espacial limitada de una red de estaciones fijas y el sesgo que introduce la percepción social cuando se contrasta con los datos objetivos [8].

1.5 Quién es SIMA

El Sistema Integral de Monitoreo Ambiental (SIMA) de Nuevo León inició operaciones el 20 de noviembre de 1992 con cinco estaciones de monitoreo en tiempo real [17]. Hoy la red opera con 15 estaciones fijas y dos unidades móviles distribuidas en 11 municipios del área metropolitana [18]. En 2025 el gobierno estatal anunció una modernización de 14 millones de pesos para alcanzar cobertura completa de contaminantes y adoptar estándares internacionales más estrictos en ozono y partículas, según la directora de la Agencia de la Calidad del Aire [19]. Su operación se supervisa desde el C5 Ambiental, un centro de monitoreo en tiempo real [18]. SIMA y la Agencia de la Calidad del Aire son el socio formador de este reto.

2. Resumen de la revisión bibliográfica

2.1 Importancia de la medición de la calidad del aire y su impacto social

Las guías de la OMS de 2021 son el marco de referencia internacional, y su actualización redujo de forma importante los valores recomendados: el anual de $PM_{2.5}$ pasó de 10 a 5 $\mu g/m^3$, el de PM_{10} de 20 a 15 y el de NO_2 de 40 a 10 $\mu g/m^3$, además de incorporar un valor de ozono para la temporada pico de 60 $\mu g/m^3$ [4]. En México, la Semarnat anunció que desde enero de 2026 serán obligatorios valores más restrictivos para PM_{10} , $PM_{2.5}$ y ozono [7]. Desde otra línea, se ha propuesto abordar la evaluación y gestión de la calidad del aire con un enfoque de ciencia de datos [9], y hay evaluaciones integrales de la calidad del aire en megaciudades mexicanas que sirven de antecedente metodológico [10]. La literatura de salud pública ambiental añade que los datos objetivos deben integrarse con la percepción social para que las políticas sean efectivas [8].

2.2 Lo que se ha hecho sobre ozono y precursores en Monterrey

El ozono es un problema documentado en la zona desde los noventa. Una tesis doctoral de 1998 integró datos de calidad del aire, emisiones y clima y reportó que el estándar mexicano de 110 ppbv se excedió en 63 días entre 1993 y 1995 [15]. Sus episodios se asociaron con sistemas de alta presión, pasos de frentes fríos y vientos de montaña-valle que generaban subsidencia, inversión de flujo y estancamiento, y se concluyó que las emisiones industriales eran un contribuyente importante y que reducir hidrocarburos era la estrategia más efectiva [15].

Trabajos recientes confirman el papel de la meteorología. Un análisis de 2019 a 2023 en cinco municipios del área metropolitana encontró que los factores meteorológicos gobiernan sobre todo el ciclo estacional del O_3 , mientras que su distribución espacial está modulada por la interacción entre fuentes locales y transporte atmosférico; utilizó métodos no paramétricos y basados en percentiles y comparó Monterrey con otras ciudades mexicanas [14]. En la zona petroquímica de Cadereyta se evaluó directamente la influencia de NO , NO_2 y NO_x junto con variables meteorológicas sobre las concentraciones de O_3 [13]. Por su parte, el comportamiento estacional es distinto según el contaminante: las partículas aumentan en la época seca y el ozono en la húmeda, con inversión térmica, viento y orografía como factores naturales y movilidad e industria como factores antropogénicos [12]. En el caso de PM_{10} hay análisis

estadísticos de series de 2010 a 2018 en el área metropolitana [11].

3. Descripción del problema

La evidencia muestra que el ozono es uno de los contaminantes más problemáticos de la Zona Metropolitana de Monterrey (ZMM), que se forma a partir de precursores como NO, NO₂ y NO_x y que está fuertemente modulado por la meteorología [12, 14, 13]. Sin embargo, buena parte de los antecedentes se centra en un municipio, en un periodo corto o en un solo método, y el endurecimiento normativo de 2026 cambia el criterio con el que se juzgan las excedencias [7, 6]. Con base en esto, el problema de este proyecto se plantea así:

Pregunta de investigación. ¿Cómo se relacionan las concentraciones de ozono con sus precursores (NO, NO₂, NO_x) y con las variables meteorológicas (temperatura, radiación solar, viento, humedad y presión) en las estaciones de SIMA entre 2020 y 2025, y qué combinación de estas variables permite explicar y clasificar los episodios de excedencia de ozono?

4. Objetivos

Objetivo general. Identificar y cuantificar, mediante técnicas de análisis multivariado, la relación entre el ozono, sus precursores y la meteorología en la ZMM para explicar y clasificar los episodios de excedencia.

Objetivos específicos.

1. Depurar y estructurar las series de SIMA de 2020 a 2025 aplicando los rangos de operación válidos por año y parámetro.
2. Caracterizar la variación diaria, estacional y entre estaciones del O₃, NO, NO₂ y NO_x.
3. Reducir la dimensionalidad y detectar patrones conjuntos de contaminantes y meteorología (p. ej., componentes principales y conglomerados de estaciones).
4. Modelar el O₃ en función de precursores y meteorología con regresión lineal múltiple y evaluar su ajuste y validación.
5. Clasificar días o episodios con y sin excedencia de la norma de ozono mediante análisis discriminante, comparando los umbrales de 2024 y 2026 (60 y 51 ppb) aplicados a todo el periodo.

5. Justificación

Existe un consenso de que la meteorología y los precursores explican buena parte de la variabilidad del ozono en Monterrey [14, 15], pero lo que falta es un análisis multivariado que integre conjuntamente esas variables con datos recientes de varias estaciones y que lo haga bajo los umbrales de 2026. Los estudios previos estudian pocas estaciones, un solo contaminante o periodos anteriores a la norma vigente [11, 13]. Además, como el límite de ozono bajó de 0.065 a 0.051 ppm dentro del periodo de estudio [6], distinguir si un aumento de excedencias refleja un deterioro real o solo un criterio más estricto [7] exige modelos que controlen la meteorología. Los resultados servirían a SIMA y a la Agencia de la Calidad del Aire para anticipar condiciones de acumulación, orientar el control de precursores y comunicar el riesgo a la ciudadanía.

6. Descripción de las fuentes de información

La fuente principal son los datos horarios del Sistema Integral de Monitoreo Ambiental descargados del portal de SIMA para 2020 a 2025: 6 archivos, 87 hojas estación-año, 754,603 registros, 16 columnas

y 13 a 15 estaciones según el año (Tabla 2). No se incluye el año parcial de 2026. Las variables son los contaminantes criterio (PM_{10} , $PM_{2.5}$, O_3 , NO , NO_2 , NO_x , SO_2 , CO) y las meteorológicas (RH, WS, TEMP, SR, BP, WD, RAINF) [16].

Como apoyo se cuenta con el documento de rangos de los parámetros del SIMA, que establece para cada año el rango de operación válido, el rango del fabricante y notas de exclusión, y que se usará para detectar valores espurios [16]; y el documento con la ubicación de las estaciones de monitoreo.

El archivo **Etiquetas.xlsx** funciona como diccionario de los datos y tiene dos hojas. La hoja *Variables* contiene las notas de uso, la correspondencia entre las abreviaturas de las estaciones y su nombre y municipio (por ejemplo, SE es La Pastora, en Guadalupe), y la lista de contaminantes y parámetros meteorológicos con sus unidades. La hoja *Banderas* describe los códigos de validación que usa SIMA (falla eléctrica, calibración, apagado, valores repetidos, fuera de rango, entre otros) y si la hora se considera válida o inválida. Se usó para confirmar nombres y unidades de las variables; los libros de 2020 a 2025 no traen columnas de banderas, por lo que no se aplicó. Las notas del archivo hablan de promedios diarios, mientras que los libros usados son horarios, lo cual conviene confirmar con el socio formador. Los materiales PIMUS, el inventario de emisiones de 2018 y el padrón de medio ambiente no están en el repositorio y no se usaron en esta etapa; si se incorporan más adelante se describirán en el siguiente entregable.

7. Comprensión de los datos

7.1 Dimensión del dataset

Como se mencionó anteriormente, las fuentes principales que serán empleadas durante la realización de este proyecto están compuestas por las bases de datos proporcionadas por SIMA, que comprenden la información recabada desde 2020 hasta 2025 de los contaminantes presentes en el aire que han sido monitoreados por medio de las estaciones del sistema que se encuentran repartidas a lo largo del área metropolitana de Monterrey.

Estas bases de datos están organizadas y separadas por año, compuestándose por un total de 6 archivos de Excel (2020 a 2025), y a su vez, cada uno de estos se encuentra dividido por estación de monitoreo, lo que da 87 hojas estación-año. Se trabaja con 2020 a 2025, años completos; el año parcial de 2026 queda fuera de este análisis. En la siguiente tabla se muestra el número de registros y estaciones presentes en cada una de las bases de datos a analizar.

Año	Estaciones disponibles	Registros
2020	13	114,102
2021	14	122,629
2022	15	123,383
2023	15	131,370
2024	15	131,741
2025	15	131,378
Total	—	754,603

Tabla 2: Cantidad de registros y estaciones disponibles por base de datos.

Los registros presentes en las bases de datos representan las mediciones realizadas cada hora de los contaminantes y parámetros meteorológicos monitoreados por una determinada estación. Sin embargo, es importante aclarar que esto no significa que se hayan monitoreado 754,603 horas en total, ya que al haber numerosas estaciones en funcionamiento simultáneamente, una misma hora puede aparecer una vez por cada estación.

Por otro lado, en cuanto a las columnas, cada base de datos posee un total de 16 columnas que se repiten por cada estación u hoja:

- **Temporal:** fecha y hora (*date*).
- **Contaminantes:** CO, NO, NO₂, NO_X, O₃, PM₁₀, PM_{2,5}, SO₂.
- **Variables meteorológicas:** PRS, RAINF, RH, SR, TOUT, WSR, WDR.

Por lo tanto, las bases de datos originales se componen de un total de 754,603 registros y 16 columnas, aunque más adelante estos valores presentarán cambios conforme se realice la selección y limpieza de los datos.

7.2 Descripción de las variables

A continuación se encuentra la descripción e información relevante de cada una de las variables antes mencionadas.

Variable	Descripción	Unidad	Tipo	Valores posibles	Nulos (%)
CO	Monóxido de carbono	ppm	Numérica	Varía por año	13.3
NO	Monóxido de nitrógeno	ppb	Numérica	Varía por año	16.7
NO ₂	Dióxido de nitrógeno	ppb	Numérica	Varía por año	17.4
NO _X	Suma de NO y NO ₂	ppb	Numérica	Varía por año	16.8
O ₃	Ozono	ppb	Numérica	Varía por año	14.7
PM ₁₀	Partículas menores a 10 μm	$\mu\text{g}/\text{m}^3$	Numérica	Varía por año	4.6
PM _{2,5}	Partículas menores a 2.5 μm	$\mu\text{g}/\text{m}^3$	Numérica	Varía por año	25.2
SO ₂	Dióxido de azufre	ppb	Numérica	Varía por año	15.0
PRS	Presión atmosférica	mmHg	Numérica	Varía por año	5.1
RAINF	Precipitación	mm/h	Numérica	Varía por año	4.7
RH	Humedad relativa	%	Numérica	0–100	11.4
SR	Radiación solar	kW/m ²	Numérica	Varía por año	3.7
TOUT	Temperatura	°C	Numérica	Varía por año	6.9
WSR	Velocidad del viento	km/h	Numérica	Varía por año	6.9
WDR	Dirección del viento	grados (0–360°)	Numérica	0–360	8.4
Fecha/hora	Momento de la medición	–	Temporal	–	0.0

Tabla 3: Descripción e información de las variables presentes en las bases de datos. Nulos: porcentaje de las 754,603 horas de 2020–2025 sin dato en la base original.

En conjunto, 11.39 % de las celdas de las 15 mediciones está vacía en la base original.

Los valores posibles de muchas de las variables cambian según el año de medición, debido a los diferentes rangos de operación que ha establecido SIMA.

Por su parte, no todas las variables se ajustan con los objetivos que se buscan alcanzar, por lo que es de gran importancia identificar cuáles de estas pueden contribuir en mayor medida a la problemática a tratar. Con base en esto, las variables que tienen un mayor valor y relación con el objetivo central del proyecto son O₃, NO, NO₂, NO_X, TOUT, SR, WSR, WDR, RH y PRS.

Comenzando por el ozono, se podría decir que este es la pieza central y la raíz de la problemática que se busca atender, ya que, como se describió anteriormente, este es uno de los contaminantes que más problemas ha producido en la zona metropolitana. Debido a esto, es indispensable tener esta variable presente a lo largo del desarrollo del proyecto. Al O₃ lo acompañan el NO y NO₂, contaminantes

precursores que le dan forma, además de NO_X , que representa de manera conjunta estos óxidos de nitrógeno. Estas variables, de la mano de parámetros meteorológicos como TOUT, SR, WSR, WDR, RH y PRS, están asociados con la formación, dispersión y el ciclo estacional del O_3 . Por lo tanto, cada una de estas variables podría brindar información importante para entender en mayor profundidad las condiciones que dan pie al aumento o excedencia de ozono.

Ahora, aunque otras variables como PM_{10} , $\text{PM}_{2.5}$, SO_2 , CO y RAINF podrían ser útiles, no son una parte central de la pregunta de investigación, y, a comparación de las otras, están relacionadas en menor medida con la temática del proyecto. Sin embargo, a pesar de que se hayan señalado a algunas de las variables como importantes o poco relevantes para el análisis, esto no quiere decir que la selección quedará exactamente de esa manera, ya que eso se determinará una vez que se haya realizado la limpieza de los datos.

7.3 Calidad de los datos

La revisión se hizo sobre los libros de 2020 a 2025 disponibles en el repositorio: 87 hojas estación-año, 754,603 registros horarios y 16 columnas (fecha y 15 mediciones). El año parcial de 2026 queda fuera del análisis, por lo que las cifras de esta parte no lo incluyen.

Valores nulos. Faltan datos en 11.39 % de las celdas (Tabla 3). La proporción es más alta en $\text{PM}_{2.5}$ (25.2 %) y en los gases NO_2 , NO, NO_X , SO_2 y O_3 (15–17 %), y se concentra en estaciones-año completas sin sensor y en 2020, donde cerca de 61 % de las horas de ozono no tiene dato. Los vacíos, por tanto, no son aleatorios. **Duplicados:** no hay filas repetidas ni pares estación-fecha duplicados. **Valores espurios:** se encontró el código centinela –9999 en 7 variables, lecturas fuera del rango de operación de SIMA (por ejemplo, vientos de más de 100 km/h y temperaturas de -60°C) y rachas de meses con el mismo valor, como NO_2 fijo en 0.5 ppb hasta 744 horas seguidas, típico de un sensor apagado. **Inconsistencias:** NO_X debe ser la suma de NO y NO_2 , pero difiere en más de 2 ppb en 7,143 registros (alrededor de 1 %).

8. Preparación de los datos

8.1 Selección de datos

Unión de bases. Los seis libros tienen la misma estructura (una hoja por estación y 16 columnas, salvo que la fecha se llama *Fecha y hora* hasta 2024 y *date* en 2025), así que no se separaron: se apilaron las 87 hojas en una sola tabla con las columnas *anio_libro* y *estacion*. No se necesitó cruzar con otras fuentes; PIMUS, el inventario de emisiones y el padrón no están en el repositorio y no se usaron.

Qué se incluyó. Se conservaron las 15 estaciones y el periodo 2020–2025. El año 2020 se mantiene en la depuración pero queda fuera de los modelos, porque tiene la mayor pérdida de datos en gases y varias estaciones sin sensor. De las 15 variables, se seleccionaron 10 (Tabla 4); se excluyeron PM_{10} , $\text{PM}_{2.5}$, SO_2 , CO y RAINF (33 % de las columnas) en esta primera versión, porque no son centrales para la pregunta de investigación y, en el caso de $\text{PM}_{2.5}$, tiene 25.2 % de nulos. Estas variables se limpiaron igualmente, de modo que pueden reincorporarse sin repetir el proceso.

Columnas objetivo. Son O_3 y la excedencia diaria: el máximo diario de la media móvil de 8 h (al menos 6 de 8 horas válidas, y días con al menos 75 % de horas válidas) que supera un umbral. Como la norma endurece el límite dentro del periodo (Sección 1.3), se fijaron dos criterios constantes en todos los años, 60 ppb y 51 ppb, para que las excedencias sean comparables. Los valores escalonados por año provienen de la consulta a SINAICA [6]; no se contrastaron aquí con el texto del Diario Oficial de la Federación, por lo que 60 y 51 ppb se manejan como criterios de trabajo sujetos a esa verificación.

Variable	Rol	Relevancia para el objetivo
O ₃	Objetivo	Variable central: se modela en forma continua y como existencia diaria.
NO, NO ₂	Precursores	Participan directamente en la formación fotoquímica de ozono.
NO _X	Precursor	Redundante con NO + NO ₂ ; en un mismo modelo se usa NO _X o el par, para evitar multicolinealidad.
TOUT, SR	Meteorología	Temperatura y radiación favorecen la formación de ozono.
WSR, WDR	Meteorología	Dispersión y transporte; la dirección es circular y se reemplaza por componentes del viento.
RH, PRS	Meteorología	Humedad y presión asociadas a estancamiento y a los episodios.

Tabla 4: Variables seleccionadas y su relevancia.

8.2 Limpieza de datos

Los libros originales no se modificaron; la limpieza se hizo en código (documento R Markdown 02_preparacion_datos.Rmd) y cada regla quedó contabilizada. Las reglas se aplican en orden y todo valor invalidado pasa a NA; ningún registro se eliminó. La Tabla 5 resume el efecto sobre las 10 variables seleccionadas.

Regla	Valores invalidados	% del total invalidado
Duplicados por estación y fecha	0	–
Centinela –9999	25	0.1
Fuera del rango de operación de SIMA por año	4,191	23.8
PRS fuera de 680–760 mmHg	4	< 0,1
RH exactamente 0 %	70	0.4
Rachas de 24 h o más con el mismo valor	13,353	75.7
Total	17,643	100

Tabla 5: Valores invalidados por regla (10 variables seleccionadas). El total equivale a 0.26 % de los valores originales con dato.

Valores espurios. Se usaron los rangos de operación por año del documento de SIMA, transcritos a un archivo versionado. La presión es la excepción: el rango del documento es único para la red, pero la presión depende de la altitud (hay estaciones con mediana de 701 mmHg y otra de 731 mmHg), y aplicarlo literalmente habría descartado miles de lecturas aparentemente válidas; se usó un rango físico de 680–760 mmHg. **NO_X:** no se recalculó ni se eliminó; se marcó con una bandera (`flag_NOX`).

Valores faltantes e imputación. *No se imputó ningún valor (0 %).* Los vacíos se concentran en estaciones–año completas, imputarlos habría inventado series enteras, y el ozono es la variable objetivo, por lo que imputarla sería circular. Tras la limpieza, el porcentaje de datos faltantes en las 10 variables pasó de 10.80 % a 11.03 %. Se trabaja con casos completos por estación–día (al menos 18 horas válidas por variable): de 32,880 estación–días, 26,757 (81.4 %) tienen ozono válido, y en 2021–2025 son 19,585 de 27,390 (71.5 %) los que tienen ozono y todos los atributos del modelo. Se descarta, por tanto, 28.5 % de los estación–días de 2021–2025 por no tener alguna variable; además, todo 2020 (5,490 estación–días, 16.7 %) queda fuera de los modelos. Quedan 6,749 horas (0.89 %) con las 10 variables vacías; se conservan en la base horaria porque documentan el hueco temporal.

Valores atípicos. Con el criterio de Tukey (más de 3 rangos intercuartílicos fuera de los cuartiles),

77,314 valores (1.15 % de los válidos) son extremos, casi todos en NO (47,610) y NO_X (22,329). *No se eliminaron ni se recortaron*: son concentraciones altas plausibles dentro del rango del instrumento y los episodios altos de ozono son precisamente lo que se quiere clasificar. Su efecto se atenuará con las transformaciones de la sección siguiente.

Variables categóricas. La estación (15 niveles, nominal) se mantiene como factor; se crearán variables *dummy* ($k - 1$ columnas) sólo en la regresión lineal y la logística. Para PCA, conglomerados y análisis discriminante no se usan, porque esos métodos requieren variables continuas. La dirección del viento no es categórica sino circular.

9. Transformación de datos

Reestructuración. La unidad de análisis de los objetivos es la estación–día, por lo que, además de la base horaria limpia (754,603 filas y 15 columnas: identificadores, las 10 variables y dos banderas), se construyó una base diaria con 32,880 filas (una por estación y día) y 31 columnas en formato ancho, y un perfil por estación para el conglomerado de estaciones. No se requirió formato largo.

Atributos derivados. Valores diarios con al menos 18 horas válidas: medias de NO, NO₂, NO_X, RH, PRS, SR y WSR; temperatura media y máxima; NOX_manana (media de 06 a 09 h, hipótesis del dominio sobre los precursores emitidos por el tráfico matutino); componentes u y v del viento, que sustituyen a la dirección circular; O3_prev (máximo de 8 h del día anterior); y calendario (mes, temporada, fin de semana y ciclo anual como seno y coseno). En 2021–2025 hay 24,931 días–estación con ozono válido, de los cuales 4,209 (16.9 %) exceden 60 ppb y 7,977 (32.0 %) exceden 51 ppb, por lo que la clase de excedencia está desbalanceada.

Discretización. No es necesaria para los predictores: los métodos previstos usan variables continuas y agrupar en intervalos descartaría información. La única discretización es la de la variable objetivo.

Normalización y escalamiento. Las medias diarias de NO, NO₂, NO_X y NOX_manana tienen asimetría alta (1.4 a 4.1), que baja a menos de 1 en valor absoluto con $\log(1 + x)$, así que se transformaron. O₃ (asimetría 0.6) y la meteorología no se transformaron: se mantiene el ozono en ppb para compararlo con los umbrales. La estandarización (media 0, desviación 1) se aplicará sólo en PCA, conglomerados y discriminante; en los modelos supervisados se ajustará con los datos de entrenamiento para evitar fuga de información, y por ello la base no guarda columnas estandarizadas. Entre los atributos hay colinealidad esperada (NO_X con NO, y temperatura media con máxima, con correlaciones cercanas a 0.9 o más), que se revisará al modelar.

10. Resumen de la preparación y acceso a la base limpia

Concepto	Valor
Registros horarios originales (2020–2025)	754,603
Variables originales (sin fecha, estación ni año)	15
Variables seleccionadas	10
Datos faltantes originales (15 / 10 variables)	11.39 % / 10.80 %
Datos faltantes tras la limpieza (10 variables)	11.03 %
Registros duplicados eliminados	0
Valores invalidados (convertidos a vacío)	17,643 (0.26 %)
Valores imputados	0
Registros eliminados	0
Estación–días de la base diaria (columnas)	32,880 (31)
Estación–días completos en 2021–2025	19,585 (71.5 %)

Tabla 6: Resumen de la preparación de datos.

La base diaria limpia (`sima_diaria_estacion.csv`) y el código que la genera están en el repositorio del equipo: <https://github.com/Ricardo-B04/sima-monitoreo-ambiental>, ruta `datos/procesados/`. La base horaria limpia (754,603 filas) no se entrega como archivo; se reproduce ejecutando `02_preparacion_datos.R` sobre los libros originales. El repositorio es público y los profesores tienen acceso; el archivo `.csv` se subió al repositorio mediante `commit` y `push`.

11. Declaratoria de uso de inteligencia artificial

Opción B. Se utilizó IA de la siguiente forma:

- **Herramienta:** Posit Assistant, asistente de IA generativa integrado en RStudio.
- **Uso realizado:** apoyo en la exploración de las bases, en la escritura del código en R para la limpieza y transformación (documentos R Markdown), en el cálculo de las cifras reportadas y en la redacción de borradores de las secciones indicadas. No se utilizó IA para la investigación previa (introducción y revisión bibliográfica) tal como existía antes de este trabajo; el uso se limitó a lo descrito.
- **Secciones donde se utilizó:** Comprensión de los datos (calidad), Preparación de los datos, Transformación de datos y Resumen de la preparación.
- **Validación realizada por los estudiantes:** se revisó y verificó el código y las cifras contra las bases originales, y se asume la responsabilidad del contenido final entregado. La revisión consistió en ejecutar los documentos R Markdown (`01_comprension_datos.Rmd` y `02_preparacion_datos.Rmd`) y contrastar las cifras de las tablas del informe con su salida.

Referencias

- [1] World Health Organization (2021). *WHO global air quality guidelines: particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Ginebra: OMS. <https://iris.who.int/handle/10665/345329>
- [2] Pérez Velasco, R., & Jarosińska, D. (2022). Update of the WHO global air quality guidelines: Systematic reviews – An introduction. *Environment International*, 170, 107556. doi:10.1016/j.envint.2022.107556
- [3] KAPSARC Data Portal. *WHO global air quality guidelines* (resumen de la guía de la OMS 2021). <https://datasource.kapsarc.org/explore/assets/who-global-air-quality-guidelines/>
- [4] Amini, H. (2021). WHO Air Quality Guidelines Need to be Adopted. *International Journal of Public Health*, 66, 1604483. doi:10.3389/ijph.2021.1604483
- [5] Secretaría de Salud (2021). NOM-025-SSA1-2021, Salud ambiental. Criterio para evaluar la calidad del aire ambiente con respecto a las partículas suspendidas PM₁₀ y PM_{2.5}. *Diario Oficial de la Federación*, 27 de octubre. https://dof.gob.mx/nota_detalle.php?codigo=5633855&fecha=27/10/2021
- [6] Sistema Nacional de Información de la Calidad del Aire (SINAICA), INECC. Normas Oficiales Mexicanas de salud ambiental (incluye NOM-020-SSA1-2021 para ozono). <https://sinaica.inecc.gob.mx/pags/noms.php>
- [7] Endurecerán la medición de la calidad del aire (2025, 11 de diciembre). *El Universal de México*. <https://link.gale.com/apps/doc/A867382483/GIC?u=itesmgic&sid=ebsco&xid=717c98d7>
- [8] Sánchez-Martínez, D. V. (2026). De la medición objetiva a la percepción social en la salud pública ambiental. *TEPEXI Boletín Científico de la Escuela Superior Tepeji del Río*, 13(26), 15–20. doi:10.29057/estr.v13i26.17315
- [9] Represa, N. S. (2020). *Elaboración e implementación de una propuesta metodológica para la evaluación y gestión de la calidad del aire mediante el enfoque de la ciencia de datos* (Tesis doctoral). Universidad Nacional de La Plata.

- [10] Molina, L. T., & Molina, M. J. (Eds.) (2002). *Air quality in the Mexico megacity: an integrated assessment* (Vol. 2). Dordrecht: Kluwer Academic Publishers.
- [11] Aguirre-López, M. A., Rodríguez-González, M. A., Soto-Villalobos, R., Gómez-Sánchez, L. E., Benavides-Ríos, Á. G., Benavides-Bravo, F. G., Walle-García, O., & Pamanés-Aguilar, M. G. (2022). Statistical Analysis of PM₁₀ Concentration in the Monterrey Metropolitan Area, Mexico (2010–2018). *Atmosphere*, 13(2), 297. doi:10.3390/atmos13020297
- [12] Fajardo-Montiel, A. L., & Ramírez-Sánchez, H. U. (2023). Evolution of Air Pollution in the Monterrey Metropolitan Area, Mexico. *Asian Journal of Environment & Ecology*, 21(1), 55–75. doi:10.9734/ajee/2023/v21i1453
- [13] Jaramillo-Perez, J. M., Macías-Hernández, B. A., Tello-Leal, E., & Ventura-Houle, R. (2025). Effect of Nitrogen Oxide Concentration Levels and Meteorological Variables on Ozone (O₃) Formation in the Petrochemical Industry Area in the Monterrey Metropolitan, Mexico. *Environmental and Earth Sciences Proceedings*, 34(1), 3. doi:10.3390/eesp2025034003 (presentado en ECAS-7, 4–6 de junio de 2025)
- [14] Hernández-Romero, K., Hernández-Romero, I. M., Mendoza, A., Pérez-Rodríguez, M., Barajas-Villarruel, L. R., Medellín-Carrillo, S., González, L. T., et al. (2026). Persistent air pollution regimes and regulatory exceedances of PM₁₀, PM_{2.5}, and O₃ in the Monterrey Metropolitan Area, Mexico. *City and Environment Interactions*, 31, 100410. doi:10.1016/j.cacint.2026.100410
- [15] Martínez-Martínez, J. (1998). *Monterrey, Mexico ozone study: Air quality measurements and photochemical modeling* (Tesis doctoral). The University of Arizona. <http://hdl.handle.net/10150/282697>
- [16] SIMA (2026). *Rangos de los parámetros del SIMA*. Documento proporcionado por el socio formador.
- [17] Contribuye UANL al monitoreo ambiental con renovación del SIMA. *Vida Universitaria, UANL*. <https://vidauniversitaria.uanl.mx/sustentabilidad/contribuye-uanl-al-monitoreo-ambiental-con-renovacion-del-sima/>
- [18] Gobierno de Nuevo León. Inauguran el nuevo C5 Ambiental; se fortalece la vigilancia del medio ambiente (boletín). <https://www.nl.gob.mx/es/boletines/inauguran-samuel-y-mariana-el-nuevo-c5-ambiental-se-fortalece-la-vigilancia-del-medio>
- [19] Nuevo León contará con el sistema de monitoreo ambiental más moderno del país (2025, 22 de septiembre). *ABC Noticias*. <https://abcnoticias.mx/local/2025/9/22/nuevo-leon-contara-con-el-sistema-de-monitoreo-ambiental-mas-moderno-del-pais-258023.html>